



- 评估观察序列概率: 即给定模型  $\lambda = (A, B, \pi)$  和观测序列  $O = (o_1, o_2, \dots, o_T)$ , 计算在模型  $\lambda$  下观测序列  $O$  出现的概率  $P(O | \lambda)$ 。这个问题的求解需要用到前向后向算法。
- 模型参数学习问题: 即给定观测序列  $O = (o_1, o_2, \dots, o_T)$ , 估计模型  $\lambda = (A, B, \pi)$  的参数, 使该模型下观测序列的条件概率  $P(O | \lambda)$  最大。这个问题的求解需要用到基于 EM 算法的鲍姆-韦尔奇算法。
- 预测问题, 也称为解码问题: 即给定模型  $\lambda = (A, B, \pi)$  和观测序列  $O = (o_1, o_2, \dots, o_T)$ , 求给定观测序列条件下, 最可能出现的对应的状态序列, 这个问题的求解需要用到基于动态规划的维特比算法。

HMM模型的三个基本问题

对于HMM模型, 首先我们假设Q是所有可能的隐藏状态的集合, V是所有可能的观测状态的集合, 其中, N是可能的隐藏状态数, M是所有可能的观测状态数。

$Q = \{q_1, q_2, \dots, q_N\}, V = \{v_1, v_2, \dots, v_M\}$

对于一个长度为T的序列, I对应的状态序列, O是对应的观测序列, 其中, 任意一个隐藏状态  $i \in Q$ , 任意一个观测状态  $o \in V$

$I = \{i_1, i_2, \dots, i_T\}, O = \{o_1, o_2, \dots, o_T\}$

两个基本假设

齐次马尔科夫链假设。即任意时刻的隐藏状态只依赖于它前一个隐藏状态, 如果在时刻t的隐藏状态是  $i_t = q_i$ , 在时刻t+1的隐藏状态是  $i_{t+1} = q_j$ , 则从时刻t到时刻t+1的HMM状态转移概率  $a_{ij}$  可以表示为

$a_{ij} = P(i_{t+1} = q_j | i_t = q_i)$

观察独立性假设。即任意时刻的观测状态仅仅依赖于当前时刻的隐藏状态, 这也是个为了简化模型的假设。

这样  $b_j(k)$  可以组成观测状态生成的概率矩阵B

$B = [b_j(k)]_{N \times M}$

$b_j(k) = P(o_t = v_k | i_t = q_j)$

除此之外, 我们需要一组在时刻t=1的隐藏状态概率分布  $\pi$

$\pi = [\pi(i)]_N$  其中  $\pi(i) = P(i_1 = q_i)$

一个HMM模型, 可以由隐藏状态初始概率分布  $\pi$ , 状态转移概率矩阵A和观测状态概率矩阵B决定。  $\pi, A$  决定状态序列, B决定观测序列。因此, HMM模型可以由一个三元组  $\lambda$  表示如下:

$\lambda = (A, B, \pi)$

HMM模型的定义

即给定观测序列  $O = (o_1, o_2, \dots, o_T)$ , 估计模型  $\lambda = (A, B, \pi)$  的参数, 使该模型下观测序列的条件概率  $P(O | \lambda)$  最大。这个问题的求解需要用到基于 EM 算法的鲍姆-韦尔奇算法

问题重述

第一种情况较为简单, 就是我们已经知道D个长度为T的观测序列和对应的隐藏状态序列, 即  $\{(O_1, I_1), (O_2, I_2), \dots, (O_D, I_D)\}$  是已知的, 此时我们可以很容易的用最大似然来求解模型参数。

假设样本本从隐藏状态  $q_i$  转移到  $q_j$  的频率  $A = [a_{ij}]$ ,  $\pi = [\pi_i]$

假设样本本从隐藏状态  $q_i$  且观测状态为  $v_k$  的频率  $B = [b_j(k)]$ ,  $\pi = [\pi_i]$

假设所有样本本初始隐藏状态为  $q_i$  的频率  $\pi = [\pi_i]$

可见第一种情况下求解模型还是很简单。但是在很多时候, 我们无法得到HMM样本本观测序列对应的隐藏序列, 只有D个长度为T的观测序列, 即  $\{(O_1), (O_2), \dots, (O_D)\}$  是已知的, 它的解法最常用的是鲍姆-韦尔奇算法, 其实就是基于EM算法的求解

鲍姆-韦尔奇算法原理既使用的就是EM算法的原理, 那么我们需要在E步求出联合分布  $P(O, I | \lambda)$  基于条件概率  $P(I | O, \lambda)$  的期望, 其中  $\lambda$  为当前的模型参数, 然后再再步最大化这个期望, 得到更新的模型参数  $\lambda$ 。接着不停的进行EM迭代, 直到模型参数的收敛为止。

首先来看E步, 当前模型参数为  $\lambda$ , 联合分布  $P(O, I | \lambda)$  基于条件概率  $P(I | O, \lambda)$  的期望表达式为

$L(\lambda, \tilde{\lambda}) = \sum_i P(I | O, \tilde{\lambda}) \log P(O, I | \lambda)$

在M步, 我们极大化上式, 然后得到更新后的模型参数如下

$\tilde{\lambda} = \arg \max_{\lambda} \sum_i P(I | O, \tilde{\lambda}) \log P(O, I | \lambda)$

通过不断的E步和M步的迭代, 直到  $\lambda$  收敛

问题重述

我们需要先计算联合分布  $P(O, I | \lambda)$  的表达式如下:

$P(O, I | \lambda) = \prod_{t=1}^T \pi_{i_t} a_{i_t i_{t+1}} b_{i_{t+1}}(o_{t+1}) \dots a_{i_T, i_T} b_{i_T}(o_T)$

我们的步得到的期望表达式为

$L(\lambda, \tilde{\lambda}) = \sum_i P(I | O, \tilde{\lambda}) \log P(O, I | \lambda)$

将上面  $P(O, I | \lambda)$  的表达式带入我们的极大化式子, 得到的表达式如下:

$\lambda = \arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log b_j(o_t)$

因此根据拉格朗日子乘法, 我们得到  $p_i$  要极大化的拉格朗日函数为:

$\arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \gamma \sum_{i,j} (p_i - 1)$

其中,  $\gamma$  为拉格朗日系数。上式对  $p_i$  求偏导数并令结果为0, 我们得到

$\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma = 0$

从两式消去  $\gamma$ , 得到  $p_i$  的表达式为

$p_i = \frac{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij}}{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma}$

第二节中前向概率的定义可得

$P(i_1^t = i | O, \tilde{\lambda}) = \gamma_i^{(t)}(i)$

因此最终我们在M步  $p_i$  的迭代公式为

$p_i = \frac{\sum_{t=1}^T \gamma_i^{(t)}(i)}{D}$

在M步我们要极大化上式。由于  $P(I | O, \lambda) = P(I, O | \lambda) / P(O | \lambda)$ , 而  $P(O | \lambda)$  是常数, 因此我们要极大化的式子等价于:

$\lambda = \arg \max_{\lambda} \sum_i P(O, I | \lambda) \log P(O, I | \lambda)$

首先我们看看对模型参数  $\pi$  的求导。由于  $\pi$  只在式子中括号里的第一部分出现, 因此我们对  $\pi$  的极大化式子为:

$\pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i$

问题重述

我们需要先计算联合分布  $P(O, I | \lambda)$  的表达式如下:

$P(O, I | \lambda) = \prod_{t=1}^T \pi_{i_t} a_{i_t i_{t+1}} b_{i_{t+1}}(o_{t+1}) \dots a_{i_T, i_T} b_{i_T}(o_T)$

我们的步得到的期望表达式为

$L(\lambda, \tilde{\lambda}) = \sum_i P(I | O, \tilde{\lambda}) \log P(O, I | \lambda)$

将上面  $P(O, I | \lambda)$  的表达式带入我们的极大化式子, 得到的表达式如下:

$\lambda = \arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log b_j(o_t)$

因此根据拉格朗日子乘法, 我们得到  $p_i$  要极大化的拉格朗日函数为:

$\arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \gamma \sum_{i,j} (p_i - 1)$

其中,  $\gamma$  为拉格朗日系数。上式对  $p_i$  求偏导数并令结果为0, 我们得到

$\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma = 0$

从两式消去  $\gamma$ , 得到  $p_i$  的表达式为

$p_i = \frac{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij}}{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma}$

第二节中前向概率的定义可得

$P(i_1^t = i | O, \tilde{\lambda}) = \gamma_i^{(t)}(i)$

因此最终我们在M步  $p_i$  的迭代公式为

$p_i = \frac{\sum_{t=1}^T \gamma_i^{(t)}(i)}{D}$

在M步我们要极大化上式。由于  $P(I | O, \lambda) = P(I, O | \lambda) / P(O | \lambda)$ , 而  $P(O | \lambda)$  是常数, 因此我们要极大化的式子等价于:

$\lambda = \arg \max_{\lambda} \sum_i P(O, I | \lambda) \log P(O, I | \lambda)$

首先我们看看对模型参数  $\pi$  的求导。由于  $\pi$  只在式子中括号里的第一部分出现, 因此我们对  $\pi$  的极大化式子为:

$\pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i$

问题重述

我们需要先计算联合分布  $P(O, I | \lambda)$  的表达式如下:

$P(O, I | \lambda) = \prod_{t=1}^T \pi_{i_t} a_{i_t i_{t+1}} b_{i_{t+1}}(o_{t+1}) \dots a_{i_T, i_T} b_{i_T}(o_T)$

我们的步得到的期望表达式为

$L(\lambda, \tilde{\lambda}) = \sum_i P(I | O, \tilde{\lambda}) \log P(O, I | \lambda)$

将上面  $P(O, I | \lambda)$  的表达式带入我们的极大化式子, 得到的表达式如下:

$\lambda = \arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log b_j(o_t)$

因此根据拉格朗日子乘法, 我们得到  $p_i$  要极大化的拉格朗日函数为:

$\arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \gamma \sum_{i,j} (p_i - 1)$

其中,  $\gamma$  为拉格朗日系数。上式对  $p_i$  求偏导数并令结果为0, 我们得到

$\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma = 0$

从两式消去  $\gamma$ , 得到  $p_i$  的表达式为

$p_i = \frac{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij}}{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma}$

第二节中前向概率的定义可得

$P(i_1^t = i | O, \tilde{\lambda}) = \gamma_i^{(t)}(i)$

因此最终我们在M步  $p_i$  的迭代公式为

$p_i = \frac{\sum_{t=1}^T \gamma_i^{(t)}(i)}{D}$

在M步我们要极大化上式。由于  $P(I | O, \lambda) = P(I, O | \lambda) / P(O | \lambda)$ , 而  $P(O | \lambda)$  是常数, 因此我们要极大化的式子等价于:

$\lambda = \arg \max_{\lambda} \sum_i P(O, I | \lambda) \log P(O, I | \lambda)$

首先我们看看对模型参数  $\pi$  的求导。由于  $\pi$  只在式子中括号里的第一部分出现, 因此我们对  $\pi$  的极大化式子为:

$\pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i$

问题重述

我们需要先计算联合分布  $P(O, I | \lambda)$  的表达式如下:

$P(O, I | \lambda) = \prod_{t=1}^T \pi_{i_t} a_{i_t i_{t+1}} b_{i_{t+1}}(o_{t+1}) \dots a_{i_T, i_T} b_{i_T}(o_T)$

我们的步得到的期望表达式为

$L(\lambda, \tilde{\lambda}) = \sum_i P(I | O, \tilde{\lambda}) \log P(O, I | \lambda)$

将上面  $P(O, I | \lambda)$  的表达式带入我们的极大化式子, 得到的表达式如下:

$\lambda = \arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log b_j(o_t)$

因此根据拉格朗日子乘法, 我们得到  $p_i$  要极大化的拉格朗日函数为:

$\arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \gamma \sum_{i,j} (p_i - 1)$

其中,  $\gamma$  为拉格朗日系数。上式对  $p_i$  求偏导数并令结果为0, 我们得到

$\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma = 0$

从两式消去  $\gamma$ , 得到  $p_i$  的表达式为

$p_i = \frac{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij}}{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma}$

第二节中前向概率的定义可得

$P(i_1^t = i | O, \tilde{\lambda}) = \gamma_i^{(t)}(i)$

因此最终我们在M步  $p_i$  的迭代公式为

$p_i = \frac{\sum_{t=1}^T \gamma_i^{(t)}(i)}{D}$

在M步我们要极大化上式。由于  $P(I | O, \lambda) = P(I, O | \lambda) / P(O | \lambda)$ , 而  $P(O | \lambda)$  是常数, 因此我们要极大化的式子等价于:

$\lambda = \arg \max_{\lambda} \sum_i P(O, I | \lambda) \log P(O, I | \lambda)$

首先我们看看对模型参数  $\pi$  的求导。由于  $\pi$  只在式子中括号里的第一部分出现, 因此我们对  $\pi$  的极大化式子为:

$\pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i$

问题重述

我们需要先计算联合分布  $P(O, I | \lambda)$  的表达式如下:

$P(O, I | \lambda) = \prod_{t=1}^T \pi_{i_t} a_{i_t i_{t+1}} b_{i_{t+1}}(o_{t+1}) \dots a_{i_T, i_T} b_{i_T}(o_T)$

我们的步得到的期望表达式为

$L(\lambda, \tilde{\lambda}) = \sum_i P(I | O, \tilde{\lambda}) \log P(O, I | \lambda)$

将上面  $P(O, I | \lambda)$  的表达式带入我们的极大化式子, 得到的表达式如下:

$\lambda = \arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log b_j(o_t)$

因此根据拉格朗日子乘法, 我们得到  $p_i$  要极大化的拉格朗日函数为:

$\arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \gamma \sum_{i,j} (p_i - 1)$

其中,  $\gamma$  为拉格朗日系数。上式对  $p_i$  求偏导数并令结果为0, 我们得到

$\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma = 0$

从两式消去  $\gamma$ , 得到  $p_i$  的表达式为

$p_i = \frac{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij}}{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma}$

第二节中前向概率的定义可得

$P(i_1^t = i | O, \tilde{\lambda}) = \gamma_i^{(t)}(i)$

因此最终我们在M步  $p_i$  的迭代公式为

$p_i = \frac{\sum_{t=1}^T \gamma_i^{(t)}(i)}{D}$

在M步我们要极大化上式。由于  $P(I | O, \lambda) = P(I, O | \lambda) / P(O | \lambda)$ , 而  $P(O | \lambda)$  是常数, 因此我们要极大化的式子等价于:

$\lambda = \arg \max_{\lambda} \sum_i P(O, I | \lambda) \log P(O, I | \lambda)$

首先我们看看对模型参数  $\pi$  的求导。由于  $\pi$  只在式子中括号里的第一部分出现, 因此我们对  $\pi$  的极大化式子为:

$\pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i$

问题重述

我们需要先计算联合分布  $P(O, I | \lambda)$  的表达式如下:

$P(O, I | \lambda) = \prod_{t=1}^T \pi_{i_t} a_{i_t i_{t+1}} b_{i_{t+1}}(o_{t+1}) \dots a_{i_T, i_T} b_{i_T}(o_T)$

我们的步得到的期望表达式为

$L(\lambda, \tilde{\lambda}) = \sum_i P(I | O, \tilde{\lambda}) \log P(O, I | \lambda)$

将上面  $P(O, I | \lambda)$  的表达式带入我们的极大化式子, 得到的表达式如下:

$\lambda = \arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log b_j(o_t)$

因此根据拉格朗日子乘法, 我们得到  $p_i$  要极大化的拉格朗日函数为:

$\arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \gamma \sum_{i,j} (p_i - 1)$

其中,  $\gamma$  为拉格朗日系数。上式对  $p_i$  求偏导数并令结果为0, 我们得到

$\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma = 0$

从两式消去  $\gamma$ , 得到  $p_i$  的表达式为

$p_i = \frac{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij}}{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma}$

第二节中前向概率的定义可得

$P(i_1^t = i | O, \tilde{\lambda}) = \gamma_i^{(t)}(i)$

因此最终我们在M步  $p_i$  的迭代公式为

$p_i = \frac{\sum_{t=1}^T \gamma_i^{(t)}(i)}{D}$

在M步我们要极大化上式。由于  $P(I | O, \lambda) = P(I, O | \lambda) / P(O | \lambda)$ , 而  $P(O | \lambda)$  是常数, 因此我们要极大化的式子等价于:

$\lambda = \arg \max_{\lambda} \sum_i P(O, I | \lambda) \log P(O, I | \lambda)$

首先我们看看对模型参数  $\pi$  的求导。由于  $\pi$  只在式子中括号里的第一部分出现, 因此我们对  $\pi$  的极大化式子为:

$\pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i$

问题重述

我们需要先计算联合分布  $P(O, I | \lambda)$  的表达式如下:

$P(O, I | \lambda) = \prod_{t=1}^T \pi_{i_t} a_{i_t i_{t+1}} b_{i_{t+1}}(o_{t+1}) \dots a_{i_T, i_T} b_{i_T}(o_T)$

我们的步得到的期望表达式为

$L(\lambda, \tilde{\lambda}) = \sum_i P(I | O, \tilde{\lambda}) \log P(O, I | \lambda)$

将上面  $P(O, I | \lambda)$  的表达式带入我们的极大化式子, 得到的表达式如下:

$\lambda = \arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log b_j(o_t)$

因此根据拉格朗日子乘法, 我们得到  $p_i$  要极大化的拉格朗日函数为:

$\arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \gamma \sum_{i,j} (p_i - 1)$

其中,  $\gamma$  为拉格朗日系数。上式对  $p_i$  求偏导数并令结果为0, 我们得到

$\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma = 0$

从两式消去  $\gamma$ , 得到  $p_i$  的表达式为

$p_i = \frac{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij}}{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma}$

第二节中前向概率的定义可得

$P(i_1^t = i | O, \tilde{\lambda}) = \gamma_i^{(t)}(i)$

因此最终我们在M步  $p_i$  的迭代公式为

$p_i = \frac{\sum_{t=1}^T \gamma_i^{(t)}(i)}{D}$

在M步我们要极大化上式。由于  $P(I | O, \lambda) = P(I, O | \lambda) / P(O | \lambda)$ , 而  $P(O | \lambda)$  是常数, 因此我们要极大化的式子等价于:

$\lambda = \arg \max_{\lambda} \sum_i P(O, I | \lambda) \log P(O, I | \lambda)$

首先我们看看对模型参数  $\pi$  的求导。由于  $\pi$  只在式子中括号里的第一部分出现, 因此我们对  $\pi$  的极大化式子为:

$\pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i$

HMM模型的三个基本问题

即给定模型  $\lambda = (A, B, \pi)$  和观测序列  $O = (o_1, o_2, \dots, o_T)$ , 求给定观测序列条件下, 最可能出现的对应的状态序列, 这个问题的求解需要用到基于动态规划的维特比算法

问题重述

我们需要先计算联合分布  $P(O, I | \lambda)$  的表达式如下:

$P(O, I | \lambda) = \prod_{t=1}^T \pi_{i_t} a_{i_t i_{t+1}} b_{i_{t+1}}(o_{t+1}) \dots a_{i_T, i_T} b_{i_T}(o_T)$

我们的步得到的期望表达式为

$L(\lambda, \tilde{\lambda}) = \sum_i P(I | O, \tilde{\lambda}) \log P(O, I | \lambda)$

将上面  $P(O, I | \lambda)$  的表达式带入我们的极大化式子, 得到的表达式如下:

$\lambda = \arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log b_j(o_t)$

因此根据拉格朗日子乘法, 我们得到  $p_i$  要极大化的拉格朗日函数为:

$\arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \gamma \sum_{i,j} (p_i - 1)$

其中,  $\gamma$  为拉格朗日系数。上式对  $p_i$  求偏导数并令结果为0, 我们得到

$\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma = 0$

从两式消去  $\gamma$ , 得到  $p_i$  的表达式为

$p_i = \frac{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij}}{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma}$

第二节中前向概率的定义可得

$P(i_1^t = i | O, \tilde{\lambda}) = \gamma_i^{(t)}(i)$

因此最终我们在M步  $p_i$  的迭代公式为

$p_i = \frac{\sum_{t=1}^T \gamma_i^{(t)}(i)}{D}$

在M步我们要极大化上式。由于  $P(I | O, \lambda) = P(I, O | \lambda) / P(O | \lambda)$ , 而  $P(O | \lambda)$  是常数, 因此我们要极大化的式子等价于:

$\lambda = \arg \max_{\lambda} \sum_i P(O, I | \lambda) \log P(O, I | \lambda)$

首先我们看看对模型参数  $\pi$  的求导。由于  $\pi$  只在式子中括号里的第一部分出现, 因此我们对  $\pi$  的极大化式子为:

$\pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i$

HMM模型的三个基本问题

即给定模型  $\lambda = (A, B, \pi)$  和观测序列  $O = (o_1, o_2, \dots, o_T)$ , 求给定观测序列条件下, 最可能出现的对应的状态序列, 这个问题的求解需要用到基于动态规划的维特比算法

问题重述

我们需要先计算联合分布  $P(O, I | \lambda)$  的表达式如下:

$P(O, I | \lambda) = \prod_{t=1}^T \pi_{i_t} a_{i_t i_{t+1}} b_{i_{t+1}}(o_{t+1}) \dots a_{i_T, i_T} b_{i_T}(o_T)$

我们的步得到的期望表达式为

$L(\lambda, \tilde{\lambda}) = \sum_i P(I | O, \tilde{\lambda}) \log P(O, I | \lambda)$

将上面  $P(O, I | \lambda)$  的表达式带入我们的极大化式子, 得到的表达式如下:

$\lambda = \arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log b_j(o_t)$

因此根据拉格朗日子乘法, 我们得到  $p_i$  要极大化的拉格朗日函数为:

$\arg \max_{\lambda} \sum_{i,j} \sum_{t=1}^T P(O, I | \lambda) \log a_{ij} + \gamma \sum_{i,j} (p_i - 1)$

其中,  $\gamma$  为拉格朗日系数。上式对  $p_i$  求偏导数并令结果为0, 我们得到

$\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma = 0$

从两式消去  $\gamma$ , 得到  $p_i$  的表达式为

$p_i = \frac{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij}}{\sum_{j=1}^N P(O, I | \lambda) \log a_{ij} + \gamma}$

第二节中前向概率的定义可得

$P(i_1^t = i | O, \tilde{\lambda}) = \gamma_i^{(t)}(i)$

因此最终我们在M步  $p_i$  的迭代公式为

$p_i = \frac{\sum_{t=1}^T \gamma_i^{(t)}(i)}{D}$

在M步我们要极大化上式。由于  $P(I | O, \lambda) = P(I, O | \lambda) / P(O | \lambda)$ , 而  $P(O | \lambda)$  是常数, 因此我们要极大化的式子等价于:

$\lambda = \arg \max_{\lambda} \sum_i P(O, I | \lambda) \log P(O, I | \lambda)$

首先我们看看对模型参数  $\pi$  的求导。由于  $\pi$  只在式子中括号里的第一部分出现, 因此我们对  $\pi$  的极大化式子为:

$\pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i = \arg \max_{\pi} \sum_{j=1}^N \sum_{t=1}^T P(O, I | \lambda) \log \pi_i$